

Präventives Retourenmanagement im eCommerce

Das wachsende Business-to-Consumer-Geschäft im eCommerce erhöht auch die Problematik der Verbraucherretouren für viele Onlinehändler. Oftmals werden Retouren durch den Verbraucher aufgrund von »Nichtgefallen« konkludent retourniert und verursachen dadurch Kosten in der Handhabung, die die Ertragssituation der Onlinehändler negativ beeinflussen können. Im vorliegenden Beitrag wird aufgezeigt, wie durch den Einsatz von Big Data Retourenquoten gesenkt werden können. Big Data wird dazu eingesetzt, Merkmalskombinationen, die Retouren ankündigen, durch Auswertung von strukturierten und unstrukturierten Daten im Kontext der eCommerce-Transaktionen in Onlineshops zu erkennen. Hierdurch werden proaktive Reaktionen möglich, mit denen Retouren vermieden werden können.

Inhaltsübersicht

- 1 Retourenproblematik bei deutschen Onlinehändlern
- 2 Technologien, Verfahren und Datenquellen
 - 2.1 Big Data
 - 2.2 Verfahren zur Datenanalyse
 - 2.3 Social Software als Datenquelle für das Retourenmanagement
- 3 Retourenvermeidung durch Web Monitoring und Big Data
 - 3.1 Analyse produktbezogener Daten
 - 3.2 Analyse kundenbezogener Daten
 - 3.3 Konsolidierung der Analysesichten
- 4 Anwendungsbeispiel Modebestellung
- 5 Potenziale, Erfahrungen und Grenzen
- 6 Literatur

1 Retourenproblematik bei deutschen Onlinehändlern

Vor allem Verbraucherretouren belasten den stark wachsenden deutschen eCommerce-Sektor im Business-to-Consumer-(B2C-)Shopping. Auf Basis des Fernabsatzvertrags (siehe u. a. § 312 b, § 355 BGB) können Verbraucher bestellte Ware in Onlineshops in einer 14-tägigen Widerrufsfrist ohne Angabe von Gründen an den Händler zurückschicken. Die Gründe einer solchen Verbraucherretoure können vielfältig sein [Pur et al. 2013; Shulman et al. 2010]. So können Retouren etwa aufgrund eines Sachmangels (z. B. beschädigte Artikel) oder Nichtgefallens der Ware verursacht werden. Nach [Pur et al. 2013] werden Rücksendungen vor allem wegen der Gründe »Artikel gefällt nicht«, »der Artikel passt nicht« und »mehrere Varianten zur Auswahl bestellt« retourniert. Das Problem für viele Verbraucher besteht in der fehlenden Haptik beim Online-Einkauf bzw. darin, dass sie aufgrund der Distanz die Ware nicht ausprobieren bzw. anprobieren können, wie dies in einem stationären Geschäft der Fall ist [Shulman et al. 2010]. Diese Überprüfung ist jedoch elementar, um die Passgenauigkeit des Produkts zu den Bedürfnissen des Konsumenten bewerten zu können. Die Bedürfnisse sind jedoch von Kunde zu Kunde unterschiedlich (wegen unterschiedlicher Größe, Farb- und Schnittpreferenzen usw.). Weiterhin unterscheiden sich Produkte voneinander und von deren angegebener Spezifikation, beispielsweise entsprechen die Herstellergrößen bzw. die Größenvorstellungen von Auftragsfertigern nicht immer den Standardkonfektionsgrößen.

Vor allem in der Bekleidungsbranche sind typischerweise Retourenquoten von bis zu 50 % der bestellten Ware anzutreffen [Pur et al. 2013].

Weiterhin ist bei vielen Onlinehändlern ein Anstieg der Retourenquote über die letzten Jahre zu verzeichnen [Pur et al. 2013]. Die Kosten einer Retourenabwicklung können die Marge der Unternehmen stark negativ beeinflussen. Im Durchschnitt betragen diese (ohne Berücksichtigung des Wertverlusts) 7,39 € [Hielscher 2013].

Vor dem Hintergrund der skizzierten Herausforderungen ist es zwingend notwendig, präventive Strategien zur Vermeidung von Retouren zu entwickeln. Für die Implementierung einer Strategie zur Retourenvermeidung ist es nötig, kundenspezifische und produktspezifische Determinanten für das Retourenverhalten zu identifizieren und diese in einer Analyse zur Erstellung von Entscheidungsregeln zu konsolidieren. Die Ausgangsdaten für diese Analyse liegen häufig nicht nur in strukturierter Form vor, sondern oftmals auch als unstrukturierte Daten im Web (bspw. in Produktbewertungsportalen). Das Monitoring von unstrukturierten Daten und eine zeitnahe oder Echtzeitauswertung stellte in der Vergangenheit eine große Herausforderung dar, der die Informationstechnik nicht gewachsen war. Eine Möglichkeit zur entscheidungsunterstützenden, zeitnahen Analyse dieser Daten kann das (Web) Monitoring mit Unterstützung von Big Data sein, das in den folgenden Abschnitten vorgestellt wird.

2 Technologien, Verfahren und Datenquellen

2.1 Big Data

Data Warehouses [Chaudhuri & Dayal 1997] und Business Intelligence [Kemper et al. 2006] waren lange die infrastrukturelle und prozessuale Basis für die Analyse und Auswertung von Daten, die aus Transaktionen stammen sowie strukturiert und semantisch homogen sind. Es wurden nur Daten erfasst, die die eigentlichen betriebswirtschaftlichen Vorgänge repräsentieren, eine klare und bekannte Struktur haben und in ihrer Bedeutung geklärt sind. Big Data ermöglicht es nun, Daten zu erschließen, die bisher einer Auswertung

und Analyse unzugänglich waren. Diese Daten übertreffen quantitativ deutlich die in Enterprise-Resource-Planning-(ERP-)Systemen erfassten Mengen. Auch unterscheiden sich die von Big Data zugänglich gemachten Daten in ihrer Struktur (Morphologie). So werden verstärkt auch Daten einbezogen, die nicht aus geschäftlichen Transaktionen stammen. Beispiele für solche Daten sind Kundeninteraktionen im Kundenbeziehungsmanagement (Customer Relationship Management – CRM), wie Anrufe oder Produkte, die in einen Warenkorb gelegt, aber nicht gekauft wurden. Auch kommen Daten hinzu, die über keine standardisierte Struktur verfügen, wie dies beispielsweise bei Weblogs der Fall ist. Schließlich sollen auch Daten erfasst werden, die eine heterogene Semantik aufweisen. Dies ist z.B. bei Kundenäußerungen in sozialen Netzwerken der Fall, in denen Kunden keine standardisierten Begriffe mit festgelegten Bedeutungen verwenden.

Zur Bewältigung der in ihrer Morphologie komplexer gewordenen Daten und des gestiegenen Volumens der Daten sind eine Reihe von Technologien entwickelt worden, deren gemeinsames Auftreten unter dem Begriff »Big Data« zusammengefasst wird. Mit dem Begriff Big Data wird also nicht eine spezifische Technologie oder Sammlung von Technologien beschrieben, sondern der Einsatz unterschiedlicher Technologien mit dem Ziel, neue Informationsketten und -flüsse in Unternehmen und Organisationen zu etablieren [Bughin et al. 2010].

Die in der theoretischen Diskussion aufgeführten Vorteile von Big Data werden durch Untersuchungen des praktischen Nutzens von Big Data in einer Reihe von Fallstudien aufgezeigt [Brynjolfsson & McAfee 2007]. So konnten Einsparungen durch die Reduktion von Fehlern bei der Planung von Flugzeugeinsätzen erreicht und Umsatzsteigerungen durch zielgerichtete Werbekampagnen bewirkt werden. Big Data ermöglicht die Ausbildung von Informationsflüssen in Unternehmen und Organisationen, die in den drei Dimensionen Volumen, Variabilität und Geschwindigkeit [Zikopoulos et al. 2012]

über die bisherigen Konzepte zur Datenauswertung und Datenanalyse, wie Business Intelligence, hinausgehen. Big Data ermöglicht es, Daten mit deutlich größerem Volumen wie bisher zu verarbeiten, was die Einbeziehung zusätzlicher Daten erlaubt. Gleichzeitig kann Big Data nicht mehr nur strukturierte bzw. in ihrer Struktur festgelegte Daten, sondern auch häufig wechselnde Datenstrukturen nutzen. Schließlich hat durch Big Data auch die Geschwindigkeit der Verarbeitung zugenommen. So erfolgt statt einer in großen Abständen stattfindenden Batch-Verarbeitung zunehmend eine zeitnahe Auswertung der Daten.

2.2 Verfahren zur Datenanalyse

Während klassische Business-Intelligence-Ansätze primär auf Kennzahlenberechnung mittels einfacher mathematischer und deskriptiver statistischer Verfahren setzen, zeichnen sich Big-Data-Anwendungen durch einen breiten Einsatz fortgeschrittener statistischer Verfahren aus. Einen Überblick gibt [Zikopoulos et al. 2012]. Hierfür steht grundsätzlich die volle Breite deskriptiver (beschreibender) und induktiver (schließender) Verfahren der uni-, bi- und multivariaten Statistik zur Verfügung. Besonders bedeutsam im Kontext des Retourenmanagements sind (neben deskriptiver Statistik) die multivariaten Verfahren der Regressions- und Clusteranalyse (vgl. Abschnitte 3.1 und 3.2).

2.3 Social Software als Datenquelle für das Retourenmanagement

Social Software [Schmidt & Nurcan 2010] und Social Media sind wichtige Datenquellen für das Retourenmanagement. Social Software stützt sich auf drei Basismechanismen: soziale Produktion, Weak Ties und kollektive Entscheidungen. Jeder dieser Mechanismen ist in der Lage, wichtige Informationen für die Vermeidung von Retouren zu liefern.

Bei der sozialen Produktion von Inhalten werden die Rollen nicht im Vorhinein festgelegt. Dies bedeutet, dass prinzipiell jeder nicht

nur Leser, sondern auch Autor sein kann. Daher können durch Medien, die die soziale Produktion unterstützen (z.B. Blogs und Wiki), Kunden leicht animiert werden, sich über Produkte zu äußern. Aus solchen Äußerungen, wie beispielsweise Kritik am Produkt, kann wiederum auf eine mögliche Retourenabsicht geschlossen werden. Weitere wichtige Hinweise werden durch Assoziationen zwischen Personen geliefert, die beispielsweise durch die Nutzung des gleichen Blogs entstehen. Mithilfe von Weak Ties können die Auswirkungen einer negativen Aussage über ein Produkt abgeschätzt werden. So kann ermittelt werden, welche Kunden in der Einflussosphäre eines anderen Kunden stehen, der seine tiefe Unzufriedenheit mit einem Produkt ausgedrückt und sogar angekündigt hat, es zurückzusenden. Haben diese Kunden ebenfalls noch die Möglichkeit zur Rücksendung, kann gezielt versucht werden, diese von einer Retoure abzuhalten.

Auch kollektive Entscheidungen können Hinweise auf die Gefahr einer Retoure liefern. So können negative Bewertungen oder auffällige Muster, wie eine hohe Zahl negativer Bewertungen, trotz akzeptabler Durchschnittsbewertung Auslöser für Retouren sein. In einem solchen Fall sollte gezielt auf retourengefährdete Kunden eingegangen werden.

3 Retourenvermeidung durch Web Monitoring und Big Data

Ausgehend von den beschriebenen Herausforderungen im B2C-Onlineshopping sind Verbraucherretouren durch ein zu implementierendes datengetriebenes Retourenvermeidungssystem zu reduzieren. Dazu ist es notwendig, produkt- und kundenbezogene Informationen durch (Web) Monitoring hinsichtlich ihrer Retourenmuster zu untersuchen. Da bei dieser Analyse sowohl unstrukturierte Daten (wie aus sozialen Netzwerken und Produktbewertungsportalen) als auch strukturierte interne Daten (bspw. aus der Retourendaten-

bank) des Unternehmens einzubeziehen sind, werden Technologien aus dem Big-Data-Umfeld zur Analyse benötigt.

Diese ermöglichen es, Datenquellen in die Analyse einzubeziehen, die bisher unberücksichtigt bleiben müssen, da ihre Erfassung und Auswertung weder zeitlich noch strukturell durchführbar war. Ein Beispiel sind die Interaktionen von Kunden mit dem Warenkorb und mit Produktseiten im Onlineshop vor dem eigentlichen Kauf. Die Auswertung und die zeitnahe Reaktion auf jeden einzelnen Änderungsvorgang im Warenkorb in Verbindung mit anderen unstrukturierten Datenquellen überforderte konventionelle Auswertungssysteme deutlich. Technologien aus dem Big-Data-Umfeld hingegen sind in der Lage, nahezu in Echtzeit die erforderlichen Auswertungen und Analysen zu liefern, um präventive Strategien zu implementieren.

Auf Basis der integrierten Analyse von kunden- und produktbezogenen Informationen nach Retourenmustern kann ein methodischer Ansatz zur Retourenvermeidung etabliert wer-

den [Möhring et al. 2013]. Retourenmuster definieren dabei Auffälligkeiten von Produkt- und Kundeneigenschaften, die eine erhöhte Retourenwahrscheinlichkeit nach dem Produktkauf verursachen können. Als Ergebnis dieser Analyse kann die Darstellung von Informationen (Produkte, Produktgrößen, Zahlungsvarianten, Lieferzeiten etc.) kundenspezifisch im Onlineshop angepasst werden (vgl. Abb. 1).

Die nachfolgend beschriebenen Ansätze können mithilfe von Technologien aus dem Big-Data-Umfeld je nach shopspezifischen Anforderungen in nahezu Echtzeit bei der Interaktion des Kunden mit dem Onlineshop erfolgen.

Im Folgenden werden Möglichkeiten zur Retourenreduktion durch Monitoring von kunden- und produktbezogenen (Web-)Aktivitäten durch die Verwendung von Big Data aufgezeigt.

3.1 Analyse produktbezogener Daten

Ausgangspunkt für die Analyse produktbezogener Daten hinsichtlich Auffälligkeiten im Retourenverhalten ist eine eindeutige Identifizierung eines Produkts über verschiedene Datenquellen

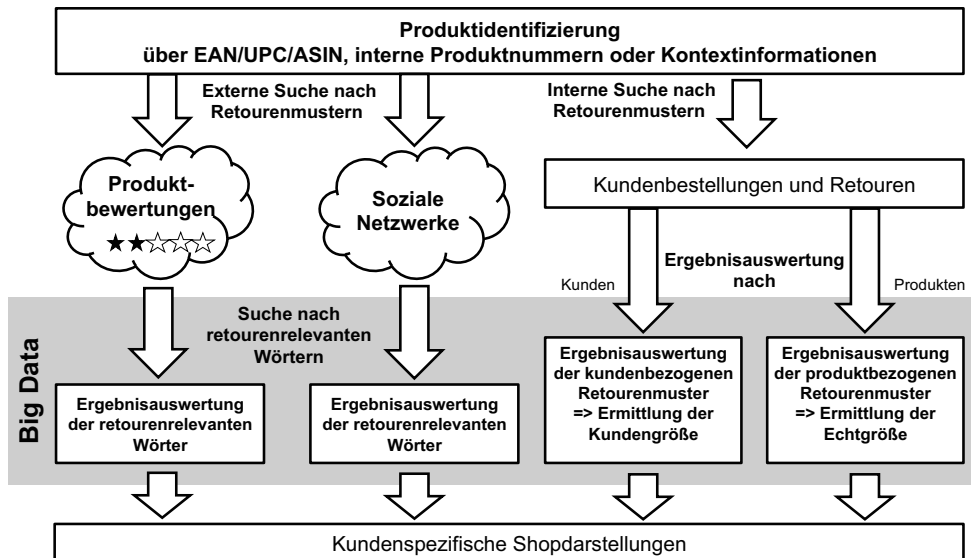


Abb. 1: Methodischer Ansatz zur Retourenvermeidung am Beispiel eines Mode-Onlineshops (entwickelt aus [Möhring et al. 2013])

hinweg. Für im eCommerce übliche Handelsware bietet sich eine eindeutige Identifikation über die EAN (European Article Number) oder den UPC (Universal Product Code) oder händler-spezifische Schlüssel wie die ASIN (Amazon Standard Identification Number) an (im Nachfolgenden als ArtikelID bezeichnet). Jedoch sind nicht in allen Datenquellen Produkte über die EAN oder den UPC sowie die ASIN zu identifizieren. Vor allem in sozialen Netzwerken wird vermehrt über den Produktnamen kommuniziert und dieser sollte daher vor allem bei der Analyse von unstrukturierten Daten verwendet werden.

Kann das Produkt über EAN, UPC, ASIN oder Produktnamen nicht im sozialen Netzwerk identifiziert werden, sollten Kontextinformationen herangezogen werden. Kontextinformationen ermöglichen es, die wahrscheinlichste Interpretation hinsichtlich Retourenmuster auszuwählen. Beispiele für Kontextinformationen sind die Produktkategorie (z.B. Kategorie Damenkleid) und die Produktmarke. So können in sozialen Netzwerken Retourenmuster eines bestimmten Produkts auf Basis ähnlicher Produkte über Produktkategorie/Markenname gefunden werden.

Basierend auf der eindeutigen Produktidentifikation werden nun Daten aus verschiedenen Quellen hinsichtlich Retourenmuster untersucht. Unternehmensexterne Daten können etwa aus dem Monitoring von Produktbewertungsportalen oder sozialen Netzwerken (wie bspw. Twitter oder Facebook) in die Analyse einbezogen werden.

Auf Basis deskriptiver Statistik (Häufigkeitsanalysen) von retourenrelevanten Wörtern und Wortgruppen können Retourenmuster erkannt und somit Wahrscheinlichkeiten für deren gemeinsames Auftreten ermittelt werden. Die Aussagefähigkeit kann über einen Scoring-Ansatz, der die Effekte mehrerer Fundstellen kombiniert, noch gesteigert werden. Retourenmuster können in diesem Anwendungsfall häufige Nennung von retourenrelevanten Gründen

bzw. Wortgruppen sein, wie beispielsweise »Artikel fällt zu groß aus«, »Artikel ist dunkler« [Pur et al. 2013, S. 35 ff.]. Diese retourenrelevanten Wörter bzw. Wortgruppen müssen bei einer Anwendung in anderen Sprachräumen (bspw. im englischsprachigen Ausland) in den jeweiligen Fremdsprachen angepasst und ggf. um regionale Aspekte bzw. Kundenanforderungen ergänzt werden. Anhand von Informationen aus Produktbewertungsportalen können je nach Datenverfügbarkeit Informationen über Probleme bei der Wahrnehmung und Nutzung des Produkts durch eine große Anzahl von Konsumenten festgestellt werden. Fällt ein Modeartikel beispielsweise häufiger eine Konfektionsgröße kleiner aus und Konsumenten sowie andere Stakeholder berichten dies in einer (signifikanten) Anzahl in entsprechenden Webportalen, so kann dies in eine präventive Strategie zur Retourenvermeidung automatisiert einbezogen werden.

Zur Verdeutlichung der Möglichkeiten aus der Analyse von Produktbewertungen hinsichtlich Retourenmustern soll das Beispiel einer mittelmäßig bewerteten Damenjeans (ASIN: Boo6BZD7CQ) beim Internetversandhändler Amazon.de dienen (Produktbewertungen $n=17$). Das Wort (bzw. in Stammkombination) »klein« wurde 13-mal und die Wörter »dunkler« und »eng« je 3-mal genannt. Die häufige Nennung von Wörtern wie »klein« deutet auf Probleme bei der angegebenen Produktgröße hin und könnte daher zu Retouren führen.

Unstrukturierte Daten aus sozialen Netzwerken können etwa fokussiert auf die Analyse von retourenrelevanten Wörtern und Wortgruppen (bspw. »fällt größer aus«) ausgewertet werden. Hierbei können Sentimentanalysen eine wichtige Rolle spielen, die mittels automatisierter Verfahren erkennen, ob ein Beitrag eine positive, negative oder ambivalente Meinung enthält [Miner et al. 2012]. Positive Meinungen über Produkte, die meist wenige Retourenmuster aufweisen, deuten auf Zufriedenheit und damit auf ein Behalten des Produkts durch den

Konsumenten hin. Negative Meinungen zeigen in der Regel Unzufriedenheit und weisen damit eine potenzielle Retourenneigung auf. Eine Implementierung ist für den Microblogging-Dienst Twitter beispielsweise mithilfe des Pakets `cran twitterR` für R möglich [Miner et al. 2012, S. 133 ff.].

Unternehmensinterne Daten können aus dem Onlineshop und dem ERP-System gewonnen werden. Die Auswertung von Produkten hinsichtlich der angegebenen Retourenprobleme (bspw. »nicht wie abgebildet«, »zu groß«), der mit der Retoure verbundenen Kosten, der Mindesthaltbarkeit von Produkten bzw. des Werteverfalls im Zeitverlauf kann helfen, produktspezifisch optimierte Ansätze zur Retourenvermeidung zu implementieren. Eine beispielhafte Auswahl der Datenquellen und -attribute ist in Tabelle 1 dargestellt.

Als Ergebnis dieses Analyseprozesses über die verschiedenen produktbezogenen Daten entstehen produktbezogene Retourenmuster, die ggf. auf neue Produkte in derselben Kategorie bzw. vom gleichen Hersteller übertragen werden können. Kenngrößen wie produkt- und produktgruppenspezifische Retourenhäufigkeiten, Retourengründe und Retourenkosten können nun transparent dargestellt werden. Da das Retourenverhalten jedoch nicht nur vom Produkt, sondern auch vom jeweiligen Kunden abhängen dürfte, muss in einem nächsten Schritt eine kundenbezogene Analyse durchgeführt werden.

3.2 Analyse kundenbezogener Daten

Die eindeutige Identifizierung eines Kunden kann innerhalb eines Unternehmens über eine Kundennummer erfolgen, die als Primärschlüssel in den verschiedenen Datenbanken (bspw. im Onlineshop, ERP- und CRM-System) vorhanden ist.

Für die Nutzeridentifikation kommen sowohl Methoden der serverseitigen als auch der clientseitigen Datensammlung zum Einsatz. Bei serverseitigen Datensammlungsmethoden steht die Analyse der Logfiles im Vordergrund, da jeder Zugriff auf eine Internetseite Nutzerspuren hinterlässt. Neben dem Einsatz von sogenannten Cookies können Kunden clientseitig beispielsweise über die Zählpixel-Methode (Web Bug) und das Page-Tagging identifiziert werden.

Durch die eindeutige Identifizierung des Kunden können nun in einem weiteren Schritt kundenspezifische Retourenmuster analysiert werden. Es können so durchschnittliche Retourenquoten pro Kunde in Abhängigkeit von Artikel und Artikelgruppen gebildet und Auffälligkeiten im Retourenverhalten hinsichtlich des Alters, Geschlechts und der durchschnittlichen Kosten, des Zustands der retournierten Ware und der Retourengründe identifiziert werden. Darauf aufbauend können die Kunden hinsichtlich ihres Retourenverhaltens mittels einer Clusteranalyse segmentiert und auf die vorhandenen Segmentierungskriterien abgebildet werden. Die Anwendung von Assoziationsanalysen ermöglicht etwa die Aufdeckung des kunden-

Datenquellen/ Tabellen	Attribute					
	KategorieID	Name	...			
Artikelkategorien	KategorieID	Name	...			
Artikel	ArtikelID	KategorieID	Name	Mindesthaltbarkeit	...	
Retouren	ArtikelID	Retourengrund	Dauer bis zum Eingang	Handlingkosten	Zustand der Retoure	...
Artikelbewertungen	ArtikelID/ Artikelname	Bewertungskategorie 1	Bewertungskategorie 2	...		

Tab. 1: Analyse produktbezogener Daten

spezifischen Retourenverhaltens beim Kauf verschiedener Produkte. In Tabelle 2 ist eine vereinfachte Auswahl der Datenquellen und -attribute als Ausgangsbasis für kundenbezogene Analysen dargestellt.

3.3 Konsolidierung der Analysesichten

Nachdem die kunden- und produktbezogenen Analysen durchgeführt wurden, können die einzelnen Ergebnisse situativ zusammengeführt und Entscheidungsregeln zur Unterstützung des präventiven Retourenmanagements angewendet werden. Dabei wird beispielsweise durch eine produktbezogene Analyse ermittelt, wie die sogenannte Echtgröße (reale Konfektionsgröße im Unterschied zur ggf. abweichenden angegebenen Konfektionsgröße) eines Artikels ist und ob Abweichungen zu der im Onlineshop hinterlegten Artikelbeschreibung vorliegen. Die Echtgröße kann etwa über das Monitoring von Daten aus Produktbewertungsportalen (bspw. gehäufte Angabe »Artikel fällt kleiner aus«) und den Abgleich bereits erhaltener Retouren erfolgen (bspw. gehäufte Angabe »Artikel fällt kleiner aus« oder »Artikel passt nicht«). Durch kundenbezogene Analysen ist nun die durchschnittliche Konfektionsgröße eines Kunden bekannt. Ermöglicht wird dies durch interne Analysen der bestellten Artikel im Vergleich mit den vom Kunden retournierten Artikeln – somit kann ermittelt werden, welche Größe im Durchschnitt vom Kunden behalten

wird. Entsprechend erfolgt im Webshop eine kunden- und produktspezifische Anpassung sowie Begrenzung der Größenauswahl. Zwar erhält der Kunde immer noch eine Größenauswahl, diese ist aber auf die möglichen korrekten Größen eingeschränkt. Dadurch kann die Retourenquote ggf. gesenkt und eine entsprechende Kostenersparnis erzielt werden.

Neben der selektiven Anzeige von Produkteigenschaften (je nach kunden- und produktspezifischen Retourenmustern) können auch Zahlungsvarianten (bspw. nur Vorkasse und kein Rechnungskauf) sowie Instrumente, die nach dem Kauf wirken (bspw. keine beiliegenden Retourenscheine) auf Basis der Analyse zur Retourenreduktion gezielt eingesetzt werden.

4 Anwendungsbeispiel Modebestellung

Im nachfolgenden Beispielszenario werden kurz die Möglichkeiten dieser Analysemethoden und die Umsetzung aufgezeigt [Möhring et al. 2013]. Das Beispiel und die Vorgehensweise sind in Abbildung 2 beschrieben.

Eine Kundin hat in der Vergangenheit im Onlineshop »XYZ42« vermehrt Jeans in den Konfektionsgrößen 28, 29, 30, 31 und 32 bestellt. Da sie die Artikel nicht vorab anprobieren konnte, bestellte sie mehrere Artikel auf Auswahl und behielt durchschnittlich nur eine Jeans. Die anderen wurden aufgrund der nicht passenden Größe

Datenquellen/ Tabellen	Attribute						
Kunden	KundenID	Name	Vorname	Geschlecht	Kundenwert	Alter	...
Bestellungen	BestellID	ArtikelID	Größe/ Spezifikation	Zahlungsmethode	...		
Kundenretouren	RetourenID	KundenID	ArtikelID	Dauer bis zum Eingang	Zustand der Retoure	Handlingkosten	...

Tab. 2: Analyse kundenbezogener Daten

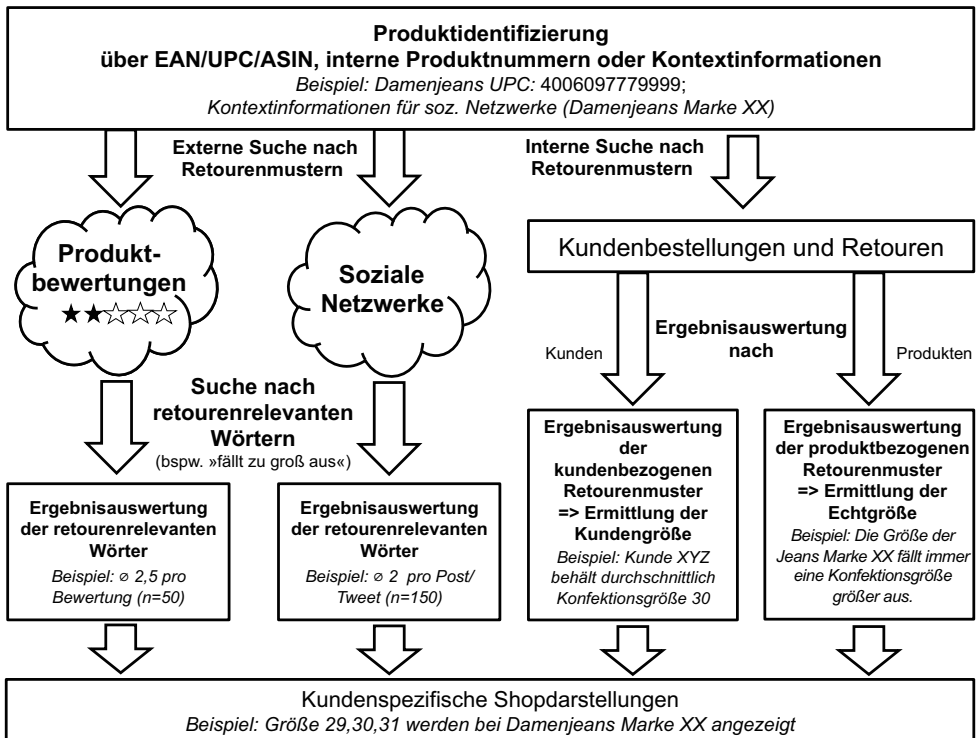


Abb. 2: Beispiel der Retourenvermeidung

wieder retourniert. Durch produktbezogene Analysen basierend auf der internen Retourendatenbank und den darin enthaltenen Informationen (bspw. oft Angabe, dass die Artikelgröße abweicht) sowie Daten aus dem Monitoring von Produktbewertungsportalen und der Qualitätssicherung können präventive Maßnahmen zur Retourenvermeidung im Webshop implementiert werden. Aus Produktbewertungsportalen konnte für Damenjeans (über UPC und EAN) ermittelt werden, dass die Konfektionsgrößen bei einigen Damenjeans häufig zu den angegebenen Größen variieren. Oft wurden Produktbewertungen je Damenjeans mit Wörtern wie »zu groß« oder »passt nicht« vom System gefunden und verarbeitet. Bei ausreichender Stichprobe und möglichen internen Daten (bspw. Kunden gaben oft ähnliche Retourengründe wie »zu groß« an) konnten somit Retourenmuster identifiziert werden. Weiterhin wurden optional

(sofern Informationen verfügbar) Meinungen über die Produkte in sozialen Netzwerken wie Facebook und Twitter gescannt. Hierbei war jedoch eine Produktidentifizierung schwieriger, da die Produkte über EAN und UPC sowie ASIN nicht identifiziert werden können. Daher wurden Kontextinformationen wie Produktkategorie (bspw. Damenjeans) und Marke sowie Produktgruppenbezeichnung verwendet, um mögliche Muster zu erkennen. Diese müssen jedoch vermehrt mit internen Daten aus der eigenen Retourendatenbank abgeglichen werden, da oft nicht die einzelnen Produkte identifiziert werden können, sondern vielmehr Aussagen über die generelle Produktlinie (bspw. »Produkte fallen generell kleiner bei Linie X42 aus«). Dieses große Datenvolumen unterschiedlichster Struktur wird nun mit einer hohen Verarbeitungsgeschwindigkeit im Webshop durch Technologien aus dem Big-Data-Umfeld ausgewertet.

Auf dieser Basis konnte nun die durchschnittliche Größe für die Kundin (Größe 30) bestimmt werden und Produktangaben (bspw. »Artikel fällt kleiner aus«) im Onlineshop verbessert werden. Bei der nächsten Bestellung der Kundin kann nun eine kundenspezifische Produktanzeige zur Retourenprävention implementiert werden. So wird bei Identifikation der Kundin (vgl. Abschnitt 3.2) nur noch eine beschränkte Auswahl an Größen (bspw. 29, 30, 31) in Abhängigkeit zu der Echtgröße des Artikels abgebildet. So können Auswahlbestellungen zwar nicht vollständig abgewendet, aber deutlich reduziert und damit Retouren entgegengewirkt werden. Eine Erweiterung dieses Beispiels um eine kundenspezifische Anzeige von Zahlungsvarianten (bspw. Vorkasse oder Rechnungsbau) und nach der Bestellung wirkende Retoureninstrumente (bspw. keine Retourenscheine beilegen) kann ebenfalls in Abhängigkeit von der Produkt- und Kundenhistorie implementiert werden. Allerdings muss der Einsatz solcher Retoureninstrumente auch hinsichtlich ihrer möglichen Wirkung auf die Kundenzufriedenheit und Kaufhäufigkeit erwogen werden.

5 Potenziale, Erfahrungen und Grenzen

Die Verknüpfung von produkt- und kundenbezogenen Daten zur angepassten Anzeige von Produkt- und weiteren Informationen in einem B2C-Onlineshop kann Möglichkeiten zur Retourenvermeidung schaffen. Weiterhin können auf Basis solcher Analysen auch allgemeine Produktangaben (bspw. Zusatz »Produkt fällt kleiner aus«) im Onlineshop verbessert und ggf. Produkteinkäufe und Lieferantenverhandlungen hinsichtlich der Retourenvermeidung besser geführt werden. Abweichungen in der Produktspezifikation können den Lieferanten für künftige Bestellungen mitgeteilt und vertragsspezifisch abgesichert werden, um so Retouren aufgrund von Differenzen in der Artikelbeschreibung zu vermeiden. In der Praxis scheiterte diese

Konzeption bisher jedoch oft an Einschränkungen der IT-Infrastruktur. Die erforderlichen Analysen waren entweder überhaupt nicht möglich oder aber nur mit erheblicher zeitlicher Verzögerung. Ein weiteres Problem war, dass wichtige Informationsquellen, insbesondere solche auf der Basis unstrukturierter Daten, wie sie in sozialen Netzwerken und Produktbewertungen vorliegen, nicht in die Analysen aufgenommen werden konnten. Durch den mit Big Data beschriebenen Technologiesprung ist es nun möglich, deutlich mehr und vor allem unstrukturierte Daten, wie sie in sozialen Netzwerken zu finden sind, in die Analysen mit einzubeziehen. Daher wurde ein Konzept zur Retourenvermeidung entwickelt, das die durch Big Data geschaffenen Potenziale aufgreift. Es nutzt deutlich mehr Datenquellen als bisherige Verfahren und liefert Informationen nahezu sofort oder zumindest in entscheidungsgerechten Zeitspannen.

Durch Einsatz dieses Konzepts mittels Web Monitoring und Big Data können die mit Retouren verbundenen Transaktionskosten gesenkt und ggf. die Kundenzufriedenheit gesteigert werden. Mögliche Herausforderungen im Bereich der Kundenakzeptanz und der Wiederkaufswahrscheinlichkeit des Kunden sowie die Anpassung dieser Ansätze an produktspezifische Onlineshops sind empirisch zu überprüfen. Erste Erprobungen in der Praxis zeigten bereits vielversprechende Ergebnisse. Die Tatsache, dass der Kunde nicht immer nur für sich bestellt oder Kundeneigenschaften sich ändern können, bildet eine Grenze des Einsatzes und kann ggf. durch größere Flexibilität der Parameter angepasst werden. Auch ist es nicht in jedem Anwendungsfall möglich, Daten über Produkte und Kunden zu erheben bzw. diese zu identifizieren. Daher sollten in diesem Bereich parallel auch traditionelle Methoden der Retourenvermeidung angewendet werden. Ein weiterer Bereich zukünftiger Forschung ist die Identifikation von retourenrelevanten Begriffen über Sprachgrenzen hinweg.

6 Literatur

- [Brynjolfsson & McAfee 2007] *Brynjolfsson, E.; McAfee, A.*: The future of the web: Beyond enterprise 2.0: MIT Sloan management review 48 (2007), 3, pp. 49-55.
- [Bughin et al. 2010] *Bughin, J.; Chui, M.; Manyika, J.*: Clouds, big data, and smart assets: Ten tech-enabled business trends to watch: McKinsey Quarterly 56 (2010).
- [Chaudhuri & Dayal 1997] *Chaudhuri, S.; Dayal, U.*: An overview of data warehousing and OLAP technology: ACM Sigmod record 26 (1997), 1, pp. 65-74.
- [Hielscher 2013] *Hielscher, H.*: Online-Händler schlagen gegen Retouren zurück: Deutsche erliegen dem Rückschick-Wahn: Wirtschaftswoche Online, 2013, www.wiwo.de/unternehmen/dienstleister/online-haendler-schlagen-gegen-retouren-zurueck-deutsche-erliegen-dem-rueckschick-wahn/7589790.html; Zugriff am 29.05.2013.
- [Kemper et al. 2006] *Kemper, H.; Mehanna, W.; Unger, C.*: Business Intelligence: Grundlagen und praktische Anwendungen: Eine Einführung in die IT-basierte Managementunterstützung. Springer-Verlag, Berlin, 2006.
- [Miner et al. 2012] *Miner, G.; Elder IV, J.; Hill, T.; Delen, D.; Fast, A.*: Practical text mining and statistical analysis for non-structured text data applications. Academic Press, Waltham, 2012.
- [Möhring et al. 2013] *Möhring, M.; Schmidt, R.; Koot, C.; Walsh, G.*: Big Data – neue Möglichkeiten im E-Commerce. Wirtschaftsinformatik und Management 5 (2013), 2, S. 48-56.
- [Pur et al. 2013] *Pur, S.; Stahl, E.; Wittmann, M.; Wittmann, G.; Weinfurter, S.*: Retourenmanagement im Online-Handel – Das Beste daraus machen, 2013, www.ibi.de/files/Retourenmanagement-im-Online-Handel_-_Das-Beste-daraus-machen.pdf; Zugriff am 29.05.2013.
- [Schmidt & Nurcan 2010] *Schmidt, R.; Nurcan, S.*: Augmenting BPM with Social Software. Business Process Management Workshops, 2010, pp. 201-206.
- [Shulman et al. 2010] *Shulman, J.; Coughlan, A.; Savaskan, R.*: Optimal reverse channel structure for consumer product returns: Marketing Science 29 (2010), 6, pp. 1071-1085.
- [Zikopoulos et al. 2012] *Zikopoulos, P. C.; Eaton, C.; DeRoos, D.; Deutsch, T.; Lapis, G.*: Understanding big data: Analytics for enterprise class hadoop and streaming data. McGraw-Hill Osborne Media, 2012.

Michael Möhring M.Sc.
 Prof. Dr. Gianfranco Walsh
 Friedrich-Schiller-Universität Jena
 Lehrstuhl für Allgemeine
 Betriebswirtschaftslehre und Marketing
 Carl-Zeiß-Str. 3
 07743 Jena
 {michael.moehring, walsh}@
 uni-jena.de
 www.marketing-wiwi.uni-jena.de

Prof. Dr.-Ing. Rainer Schmidt
 Hochschule Aalen
 Fakultät für Elektronik und
 Informatik
 Studiengang Wirtschaftsinformatik
 Beethovenstr. 1
 73430 Aalen
 rainer.schmidt@htw-aalen.de
 www.htw-aalen.de

Prof. Dr. Christian Koot
 Hochschule Aalen
 Fakultät für Elektronik und
 Informatik
 Anton-Huber-Str. 25
 73430 Aalen
 christian.koot@htw-aalen.de
 www.htw-aalen.de

Prof. Dr. Ralf-Christian Härting
 Hochschule Aalen
 Fakultät Wirtschaftswissenschaften
 Studiengang KMU
 Beethovenstr. 1
 73430 Aalen
 ralf.haerting@kmu-aalen.de
 www.kmu.htw-aalen.de

Möhring et al.: Präventives Retourenmanagement im eCommerce. HMD – Praxis der Wirtschaftsinformatik 50 (2013), 293, S. 66-75.